

# פרויקט סיום: אימון והשוואה של שני מודלי שפה על QA-קלאסיפיקציה, תרגום ו

תוצר מרכזי: קוד ניתן לשחזור +דוח ניסויי קצר עם טבלאות תוצאות מלאות

מרכזיות: קלאסיפיקציה, תרגום ושאלות-תשובות NLP בפרויקט זה תאמנו ותשוו שני מודלים שונים לביצוע שלוש משימות הדגש אינו על אימון מודלים גדולים, אלא על ניסוי מסודר: הגדרת פרומפטים, הכנת דאטה, אימון קצר, הערכה. (QA) כמותית, וניתוח ביקורתי של היתרונות והחסרונות של כל שיטת אימון

- text-to-text להתנסות באימון מודל שפה למשימות שונות בפורמט
- LoRA/Adapter כגון parameter-efficient fine-tuning לבין full fine-tuning להבין את ההבדל בין
- להעריך מודלים בעזרת מדדים שונים המתאימים לכל משימה
- להשוות באופן מסודר בין שני מודלים על אותם סטים של בדיקה
- לנסח מסקנות על איכות, זמן אימון, זמן הסקה, גודל מודל ועלות חישובית

כל סטודנט או זוג סטודנטים יבחרו שתי שיטות אימון וישוו ביניהן. ההמלצה הרשמית היא להשתמש באותו מודל בסיס כדי שההשוואה תהיה הוגנת.

יש לאמן שני מודלים. ניתן לבחור אחת משתי האפשרויות הבאות. האפשרות המומלצת היא אפשרות א

## אפשרות א: מומלצת - אותו מודל בסיס, שתי שיטות אימון

| תיאור                                                                                                              | שיטת אימון            | מודל    |
|--------------------------------------------------------------------------------------------------------------------|-----------------------|---------|
| עדכון כל פרמטרי המודל או לפחות כל שכבות ה decoder/encoder-decoder. כגון T5-small או mt5-small מתאים למודל קטן כגון | Full fine-tuning      | Model A |
| עדכון מספר קטן של פרמטרים בלבד. יש לדווח כמה פרמטרים אומנו ומה אחוזם מתוך כלל הפרמטרים                             | LoRA / Adapter / PEFT | Model B |

subset-יש להשתמש ב GPU, או מודל קטן אחר. אם אין, t5-small, flan-t5-small, mt5-small: מודלים מומלצים נמוך epochs קטן ובמספר

## Extension מול Instruction-tuned - אפשרות ב: מתקדמת

| תיאור                                                                                    | שיטת אימון/הרחבה              | מודל    |
|------------------------------------------------------------------------------------------|-------------------------------|---------|
| instruction → answer על זוגות supervised אימון                                           | SFT / Instruction fine-tuning | Model A |
| או preference pairs על QA, DPO ל-RAG הרחבה כגון קטן. אפשרות זו דורשת אישור מרצה מראש MoE | Extension                     | Model B |

prompt, אחיד. הקלט יהיה text-to-text כדי לאפשר לאותו מודל לבצע שלוש משימות שונות, יש להמיר כל דוגמה לפורמט והפלט יהיה התשובה המצופה

| משימה       | input/prompt דוגמת                                                           | target/output דוגמת         |
|-------------|------------------------------------------------------------------------------|-----------------------------|
| קלאסיפיקציה | classify sentiment: This movie was surprisingly good.                        | positive                    |
| תרגום       | translate English to French: The child opened the door.                      | L'enfant a ouvert la porte. |
| QA          | question: Where did Mary go? context: Mary went to the kitchen after school. | kitchen                     |

בדיוק, כדי שההשוואה תהיה הוגנת prompt חשוב: על שני המודלים להשתמש באותו פורמט

## דאטהסטים מומלצים

מתוך דאטהסטים מוכרים. לכל משימה מומלץ לקחת מדגם קטן כדי לעמוד subsets-יש להשתמש בדאטהסטים קטנים או ב. בהיקף של 10 שעות עבודה

| הערות                                                           | גודל מומלץ                        | דאטהסט מומלץ                      | משימה       |
|-----------------------------------------------------------------|-----------------------------------|-----------------------------------|-------------|
| לבחור דאטהסט אחד בלבד. אם יש 4 macro-F1 קטגוריות, לדווח         | Train: 1,000; Val: 200; Test: 200 | SST-2 / AG News / Emotion         | קלאסיפיקציה |
| או English→French מומלץ בגלל זמינות German→English מודלים ודאטה | Train: 1,000; Val: 200; Test: 200 | OPUS Books / Tatoeba / WMT subset | תרגום       |
| question + context להמיר לפורמט → answer.                       | Train: 1,000; Val: 200; Test: 200 | SQuAD subset / bAbI QA            | QA          |

ל-300-500 דוגמאות למשימה, אך חובה לדווח על כך בדוח train-אם זמן האימון ארוך מדי, מותר להקטין את ה. יש ליצור חלוקה קבועה וזהה לשני המודלים. אין להעריך על דוגמאות ששימשו באימון

| גודל מומלץ לכל משימה | שימוש                                  | סט         |
|----------------------|----------------------------------------|------------|
| דוגמאות 500-1,000    | אימון המודל                            | Train      |
| דוגמאות 100-200      | hyperparameters בחירת / early stopping | Validation |
| דוגמאות 100-200      | הערכת התוצאה הסופית בלבד               | Test       |

## דרישות אימון

כל אחד משני המודלים יאומן על שלוש המשימות. אפשר לאמן מודל רב-משימתי אחד לכל שיטת אימון, או לאמן שלושה מודלים קטנים נפרדים לכל משימה. ההמלצה היא אימון רב-משימתי אחד לכל שיטה, שבו מערבבים דוגמאות משלוש המשימות ברור לכל משימה prefix ומוסיפים

- מומלץ: 1-3 epochs מספר
- מומלץ: 4-16, בהתאם לזיכרון Batch size
- 5-1e-5 עד 5-1e-5 Learning rate מומלץ ל full fine-tuning
- 4-1e-4 עד 5-1e-4 Learning rate מומלץ ל LoRA/PEFT
- tokens מומלץ: 128-256 Max input length
- tokens תרגום 64, QA 32 tokens, Max output length: 5 קלאסיפיקציה
- סופי לכל מודל checkpoint יש לשמור
- inference יש לתעד זמן אימון וזמן

## מדדי הערכה

יש לחשב מדדים מתאימים לכל משימה. אין להשתמש באותו מדד לכל המשימות ללא הצדקה

| מדדים אופציונליים                            | מדדים חובה                                                 | משימה       |
|----------------------------------------------|------------------------------------------------------------|-------------|
| Confusion matrix, per-class precision/recall | Accuracy, Macro-F1                                         | קלאסיפיקציה |
| METEOR, COMET אם זמן                         | BLEU, chrF                                                 | תרגום       |
| Answer length error, semantic similarity     | Exact Match, Token-level F1                                | QA          |
| GPU memory, model size on disk               | Train time, inference time, number of trainable parameters | כללי        |

# חישוב ציון כולל מנורמל

כדי להשוות בין שני המודלים מעבר למשימה בודדת, יש לחשב ציון כולל. מאחר שהמדדים בסקאלות שונות, יש לנרמל כל מדד לסקאלה של 0-100.

הגדרה מומלצת:

$$\begin{aligned} \text{classification\_score} &= 100 * \text{Macro\_F1} \\ \text{translation\_score} &= \text{BLEU} \\ \text{qa\_score} &= 100 * \text{QA\_F1} \end{aligned}$$

$$\text{overall\_score} = (\text{classification\_score} + \text{translation\_score} + \text{qa\_score}) / 3$$

מתקבל בטווח 0-1, יש להכפיל ב-100. אם הוא מתקבל בטווח 0-100, אין להכפיל BLEU אם בדוח הסופי חובה לכלול את הטבלאות הבאות. ניתן להוסיף טבלאות נוספות לפי הצורך.

## טבלה 1: פרטי המודלים והאימון

| שדה                            | Model A: Full FT | Model B: LoRA/PEFT |
|--------------------------------|------------------|--------------------|
| Base model                     |                  |                    |
| Training method                |                  |                    |
| Trainable parameters           |                  |                    |
| Trainable %                    |                  |                    |
| Epochs                         |                  |                    |
| Learning rate                  |                  |                    |
| Batch size                     |                  |                    |
| Max input/output length        |                  |                    |
| Train examples per task        |                  |                    |
| Training time                  |                  |                    |
| Hardware / runtime environment |                  |                    |

## טבלה 2: תוצאות קלאסיפיקציה

| מודל      | Accuracy | Macro-F1 | Precision Macro | Recall Macro | הערה קצרה |
|-----------|----------|----------|-----------------|--------------|-----------|
| Model A   |          |          |                 |              |           |
| Model B   |          |          |                 |              |           |
| הפרש: B-A |          |          |                 |              |           |

## טבלה 3: תוצאות תרגום

| מודל      | BLEU | chrF | Average output length | דוגמת שגיאה נפוצה |
|-----------|------|------|-----------------------|-------------------|
| Model A   |      |      |                       |                   |
| Model B   |      |      |                       |                   |
| הפרש: B-A |      |      |                       |                   |

## QA טבלה 4: תוצאות

| מודל    | Exact Match | Token F1 | Average answer length | דוגמת שגיאה נפוצה |
|---------|-------------|----------|-----------------------|-------------------|
| Model A |             |          |                       |                   |
| Model B |             |          |                       |                   |

|           |  |  |  |  |
|-----------|--|--|--|--|
| הפרש: B-A |  |  |  |  |
|-----------|--|--|--|--|

### טבלה 5: ציון כולל ועלות חישובית

| מודל      | Classification score | Translation score | QA score | Overall score | Train time | Inference time / 100 examples |
|-----------|----------------------|-------------------|----------|---------------|------------|-------------------------------|
| Model A   |                      |                   |          |               |            |                               |
| Model B   |                      |                   |          |               |            |                               |
| הפרש: B-A |                      |                   |          |               |            |                               |

### טבלה 6: דוגמאות איכותניות

| משימה          | Input | Gold answer | Model A output | Model B output | ניתוח קצר |
|----------------|-------|-------------|----------------|----------------|-----------|
| Classification |       |             |                |                |           |
| Translation    |       |             |                |                |           |
| QA             |       |             |                |                |           |
| Failure case   |       |             |                |                |           |
| Success case   |       |             |                |                |           |

### ניתוח נדרש בדוח

- הדוח אינו צריך להיות ארוך, אך חייב לכלול ניתוח ולא רק מספרים. יש לענות על השאלות הבאות:
1. ?איזו שיטת אימון השיגה תוצאה טובה יותר בכל אחת משלוש המשימות
  2. ?QA-האם אותו מודל היה טוב בכל המשימות, או שהיו הבדלים בין קלאסיפיקציה, תרגום ו
  3. ?האם השיפור באיכות מצדיק את זמן האימון או מספר הפרמטרים המאומנים
  4. ?באילו סוגי דוגמאות כל מודל נכשל
  5. ?hallucination קצרים מדי, ארוכים מדי, או outputs האם נצפתה בעיה של

### תוצרי הגשה

| דרישה                                  | תוצר        |
|----------------------------------------|-------------|
| מלאים Notebook או Python קבצי          | קוד         |
| הוראות התקנה והרצה, כולל גרסאות ספריות | README      |
| עם כל המדדים CSV/JSON/XLSX             | קובץ תוצאות |
| באורך 4-6 עמודים DOCX או PDF           | דוח         |
| לפחות 5 דוגמאות איכותניות בטבלה        | דוגמאות פלט |